Le mémoire (version ENSAE), concept par concept

Ce que chaque outil résout, comment il marche, et la phrase qui l'explique en trente secondes

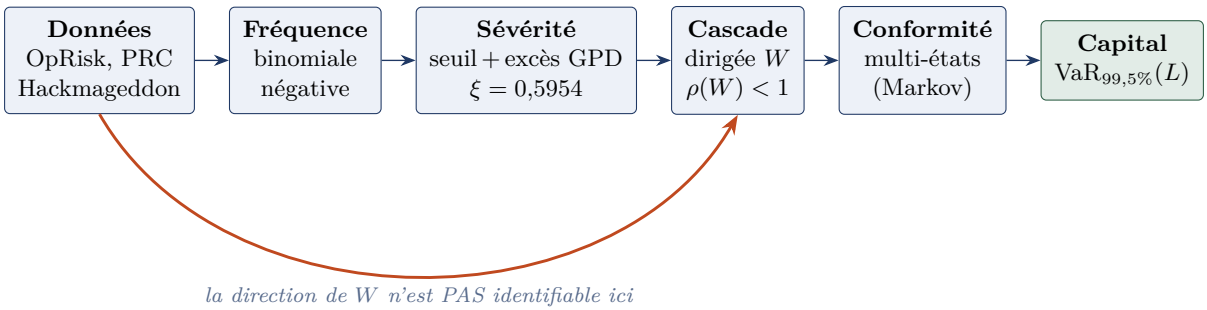
Kélian Kaddouri

Mise à jour du 28 octobre 2026

À quoi sert ce document. Le mémoire empile une vingtaine d'outils, chacun choisi pour une raison précise, et il est facile de les manipuler correctement sans savoir les *défendre*. Chaque section suit le même gabarit : le problème que l'outil résout, l'idée en langage courant, la formule, ce que ça donne dans notre cas, la phrase à dire à voix haute quand on vous interroge, et le piège à éviter.
La phrase encadrée en vert est le livrable de chaque section. Si vous ne retenez qu'elle, vous tenez l'oral.
Un second document, `cours_memoire_questions_ensae`, reprend le rapport ENSAE chapitre par chapitre (partie X). Pour chacun : le chapitre en une phrase, un encadré de ce qu'il faut savoir *par cœur*, puis les questions que le jury peut poser, avec la réponse à tenir et le folio où s'appuyer. C'est le document à relire la veille de la soutenance.

Base ENSAE du 19 octobre ; réponses actualisées au 28 octobre 2026. Ce cours conserve les folios du rapport ENSAE de 100 pages (`memoire/main_ensae.pdf`), corrigé le 19 octobre. Les réponses intègrent les rectifications de portée les plus récentes. Une partie finale, explicitement hors rapport déposé, présente les compléments Institut du 27 octobre. L'exposé ENSAE doit tenir en **15 minutes au maximum**, questions séparées. Trois points ont changé depuis la version pour le manuscrit de 199 pages : la **valeur de l'information** (la réduction de la plage par un registre d'incidents est de 32,7 % en moyenne, de 22 à 44 % selon la graine, et non 66 % ; aucune paire ne se détache, quatre dépendances levant chacune de 11,2 à 13,3 %) ; le **transfert du risque** (coût de financement de 8,0 à 2,9 M€, soit −64 % ; pertes conservées comprises, de 11,67 à 5,12, soit −56 % ; seuil de 64 % de portée sans allègement de capital, et non 78 %) ; et la **part insensible au sens** (79 % du capital : socle 61 % et plancher commun aux sommets 18 %). Rappel des erreurs de fond déjà corrigées à l'oral : le capital est une $\mathrm{VaR}_{99{,}5\,\%}$ *non centrée* ; seul le *groupe de tête*, P1 et P4, résiste à l'ignorance de la direction ; l'écart entre les deux états de conformité est *posé* pour les quatre canaux, seuls les niveaux de référence de la fréquence et de la détection étant calibrés. Les nombres du cours se retrouvent dans le rapport, ou dans le supplément en ligne, ou dans les sorties versionnées.

Le schéma d'ensemble. Cinq étages, de la donnée au capital. Chaque partie de ce document en traite un.



La flèche rouge situe l'information manquante sur les liens entre piliers. Les lois de pertes et la fréquence de référence sont ajustées sur les données ; la force des liens et la correspondance entre conformité et paramètres restent posées. L'identification partielle examine ici la direction, conditionnellement à la force symétrique retenue.

Table des matières

I. D'où viennent les nombres **4**

1 Les trois sources, et ce que chacune peut dire **4**

2 La conversion Jacobs **4**

3 Le seuil de collecte, et les trois fréquences **5**

4 Mesurer un biais au lieu de le déclarer **5**

II. Combien d'incidents par an **6**

5 Le processus de Poisson, et pourquoi il ne suffit pas **6**

6 La surdispersion et la négative binomiale **6**

7 Pourquoi pas un processus de Hawkes **7**

III. Combien coûte un incident **7**

8 Pourquoi la théorie des valeurs extrêmes **7**

9 Les deux théorèmes fondateurs **8**

10 La méthode des excès et la loi de Pareto généralisée **8**

11 Le choix du seuil **9**

IV. Comment les pertes s'additionnent **10**

12 Le modèle collectif **10**

13 VaR, TVaR, et pourquoi le SCR est une VaR **10**

V. Comment un problème en entraîne un autre **11**

14 La convention d'indices, à ne jamais improviser **11**

15 La matrice de contagion et sa normalisation **11**

16 L'inverse de Leontief et la sous-criticité **12**

17 Le seuil de déclenchement, et le rôle de la loi normale **12**

18 Les copules et la dépendance de queue **13**

19 Les états de conformité : Vasicek à l'échelle rapide, Markov à l'échelle lente **14**

VI. Ce qu'on ne peut pas savoir, et pourquoi **15**

20 La décomposition $W = S + A$ **15**

21 Le renversement du temps et la fluctuation martingale **16**

22 Le test placebo **16**

23 La production d'entropie **17**

24 z scalaire ou z par paire **18**

25 Le troisième échec : le schéma existe, il n'est pas rempli **18**

26 La matrice ordonnée p_{jk} **19**

27 L'identification partielle **19**

28 Pourquoi A compte quand même **20**

VII. À quel point on y croit **20**

29 Le bootstrap **20**

30 Les tests d'adéquation **20**

31 Les trois étages d'incertitude **21**

32 VaR prédictive et VaR robuste **21**

VIII. Les outils annexes **22**

33 Le kappa de Cohen **22**

34 La valeur d'information **22**

35 Le bayésien conjugué **23**

IX. Du capital à la décision **23**

36 À quelle échelle se lit un SCR **23**

37 Détenir ou transférer **24**

Compléments Institut après dépôt **26**

38 Trois lectures de la taille **26**

39 Un quantile nul n'est pas une absence d'incident **26**

40 Apprentissage statistique : un gain à vérifier hors période d'ajustement **27**

41 Descriptions SAS : observer un récit et identifier un mécanisme **27**

I. D'où viennent les nombres

1 Les trois sources, et ce que chacune peut dire

Le problème. Pour chiffrer un capital, il faut trois choses : combien d'incidents par an, combien coûte un incident, et comment les incidents s'enchaînent. Aucune source publique ne porte les trois.

L'idée. On ne cherche pas *la* bonne base, on répartit les questions entre les sources selon ce que chacune peut porter, et on déclare ce qui manque.

Chez nous. Trois bases pour les marges, un corpus pour l'ordre, deux sources de contrôle.

- **SAS OpRisk Global Data** : pertes opérationnelles en dollars, catégories de Bâle ; 582 pertes cyber × finance sur 2000–2026 pour la sévérité, 4 329 transitions annuelles pour le test de direction. Elle porte le **niveau** de sévérité et la fréquence d'entrée. Son pas est annuel, ce qui efface l'ordre des événements.
- **Privacy Rights Clearinghouse (PRC)** : 15 053 incidents retenus, exprimés en *nombre d'enregistrements compromis*, pas en euros. Elle sert d'**axe de sensibilité** après conversion, et de clé de répartition ($\lambda_{ref} = 341$).
- **Hackmageddon** : 1 041 incidents, 840 à vecteur identifié. Elle donne les **parts par vecteur d'attaque**, jamais un niveau ; c'est une citation, non recalculable.
- **Dix rapports post-incident** (22 transitions) : peu de volume, mais une enquête y reconstitue la *séquence* des défaillances. C'est la seule source qui porte l'**ordre**.
- **VERIS** (10 591 incidents) montre que le bon schéma existe sans être rempli, et **quatre SFCR** donnent l'échelle d'entité.

À dire à voix haute. *Aucune base ne dit tout. OpRisk donne le niveau mais pas l'ordre, PRC donne du volume mais pas d'euros, Hackmageddon la structure par vecteur, et les rapports d'enquête donnent l'ordre mais pas le volume. Je les utilise pour ce que chacune peut porter, et je dis explicitement ce qui reste absent.*

Le piège. Ne jamais laisser croire qu'on a « une base de données DORA ». Elle n'existe pas. Le règlement met en place le reporting qui la produira, et c'est justement l'objet de la recommandation finale du mémoire.

2 La conversion Jacobs

Le problème. PRC compte des enregistrements compromis, pas des euros. Il faut passer de l'un à l'autre.

L'idée. Une régression publiée établit, sur un échantillon d'incidents dont on connaît à la fois le nombre d'enregistrements et le coût, une relation log-log entre les deux.

La formule. $\ln L = 7{,}68 + 0{,}76 \ln X + \varepsilon$, où X est le nombre d'enregistrements et L la perte en dollars. Le résidu a un écart-type de 0,523 en logarithme : à volume donné, le coût réel varie d'un facteur 2,4 autour de la droite, à 90 %.

Chez nous. L'exposant $0{,}76 < 1$ dit que le coût croît *moins vite* que le nombre d'enregistrements : un incident dix fois plus gros ne coûte pas dix fois plus cher, mais environ six fois. Il y a un coût fixe important dans tout incident.

À dire à voix haute. *Jacobs n'est pas un lien fréquence-sévérité, c'est une conversion de sévérité seule : elle transforme un nombre d'enregistrements en montant. Et mon capital principal n'en dépend pas, il est calculé sur OpRisk, qui est déjà en dollars.*

Le piège. Le modèle traitait d'abord cette conversion comme *exacte*, en ignorant le résidu. En le réinjectant enregistrement par enregistrement, le niveau du surcoût PRC bouge de 7 % mais l'intervalle ne s'élargit presque pas, le bruit se moyennant dans l'ajustement GPD (ξ passe de 1,03 à 1,07, matériel complémentaire). Et ne jamais lire $\xi_{\text{PRC}} = 1{,}03$ comme un risque plus lourd : une puissance multiplie l'indice de queue par son exposant, donc cet indice décrit la queue des *enregistrements* transportée en euros.

3 Le seuil de collecte, et les trois fréquences

Le problème. Trois nombres du mémoire portent le nom de « fréquence » et vont de 0,092 à 341 par an. Confondre deux d'entre eux fait dire n'importe quoi.

L'idée. Ils ne comptent pas la même chose, parce qu'ils ne sont pas lus au même endroit. Une base ne retient que les pertes au-dessus d'un **seuil de collecte** : le taux qu'on y lit est celui des incidents *matériels*, générateurs d'une perte enregistrée, et non celui de tous les incidents au sens du reporting réglementaire.

Chez nous.

$\lambda_{ref} = 341/\text{an}$	notifications PRC, organisations financières	*clé de répartition* par vecteur
$\lambda = 21{,}6/\text{an}$	incidents TIC matériels, secteur	**l'entrée du moteur**
$\lambda_{\text{entité}} = 0{,}092/\text{an}$	les mêmes, lus à la taille de l'entité	l'échelle d'une entité

Les seaux du panel valent 0,10 (toutes firmes) et 0,21 (firmes à au moins dix événements), mais ils ne décrivent aucune entité : la lecture juste estime λ en fonction de la taille et la lit à celle de l'entité visée. La base PRC entière compte 2 150 notifications par an ; le 341 ne porte que sur les organisations financières.

> **À dire à voix haute.** *Le facteur* 3 719 *entre ma plus grande et ma plus petite fréquence n'est pas une incohérence, c'est trois niveaux d'observation. Un seul alimente le moteur, les deux autres servent à répartir et à interpréter. Le seuil de collecte est ce qui les sépare.*

Le piège. Le taux λ est une propriété d'**entité**, lisible sur un panel firme-année ; la charge systémique commune, elle, ne se lit qu'au niveau **agrégé** et après retrait de tendance. Les confondre revient à imputer au risque systémique ce qui n'est qu'un effet de taille des firmes.

4 Mesurer un biais au lieu de le déclarer

Le problème. Tout le monde déclare que sa base est biaisée. Presque personne ne dit de combien. Or déclarer ne coûte rien, mesurer engage.

L'idée. Deux biais classiques d'une base de pertes se mesurent avec la base elle-même. Le **biais de taille**, parce que la base porte les actifs de la firme sinistrée. La **troncature à droite**, parce qu'elle porte la date de saisie en plus de l'année de survenance.

La formule. Pour la taille, une régression log-log $\ln L = a + b \ln(\text{actifs})$ donne l'élasticité b. Mais elle est biaisée par le seuil de collecte : une petite firme n'entre dans la base que si sa perte est anormalement grande, ce qui *aplatit* la pente. On corrige par un maximum de vraisemblance sur une lognormale **tronquée à gauche** en u_0, où la contribution de chaque observation est divisée par $1 - \Phi\big((\ln u_0 - \mu)/s\big)$. Pour la troncature à droite, on construit le triangle survenance × délai de remontée et l'on applique un **chain-ladder** aux comptes.

Chez nous. Élasticité brute 0,042 avec un R^2 de 0,005 (matériel complémentaire), ce qui *réfuterait* l'explication usuelle. Corrigée de la troncature, elle double à **0,087** [0,026 ; 0,148] et devient significative, mais reste faible : la sévérité transposée à l'entité notionnelle n'est multipliée que par 0,85 environ (0,854 au chapitre 10). Côté remontée, le délai médian est de trois ans (matériel complémentaire) et les 97 événements observés sur 2023–2025 deviennent 255 à l'ultime, soit +163 %.

À dire à voix haute. *Mes deux biais les plus souvent opposés, je ne me contente pas de les signaler : je les chiffre. Le biais de taille coûte quinze pour cent environ, pas un facteur dix. Et la baisse apparente des incidents après 2022 n'est pas une baisse du risque, c'est une remontée incomplète que le chain-ladder rattrape.*

Le piège. Les deux corrections vont en sens opposés et se compensent presque exactement sur la *perte moyenne* ($0{,}861 \times 1{,}147 = 0{,}987$). Elles ne se compensent **pas** sur le capital : à queue lourde, le quantile suit la sévérité et non la fréquence. Deux biais qui s'annulent sur l'espérance peuvent ne pas s'annuler sur le quantile, et c'est le quantile qui fait le SCR.

II. Combien d'incidents par an

5 Le processus de Poisson, et pourquoi il ne suffit pas

Le problème. Modéliser un nombre d'événements par an, sans savoir quand ils tombent.

L'idée. Si les événements arrivent indépendamment, à un rythme constant, et jamais deux exactement en même temps, alors leur nombre annuel suit une loi de Poisson. C'est le modèle de comptage par défaut, et il n'a qu'un paramètre.

La formule. $\mathbb{P}(N = k) = e^{-\lambda}\lambda^k/k!$, avec la propriété caractéristique

$$\mathbb{E}[N] = \mathrm{Var}(N) = \lambda.$$

Moyenne et variance sont *égales*. C'est à la fois sa force et sa faiblesse.

Chez nous. Cette égalité est testable, et elle est rejetée massivement. Sur 14 944 cellules entité-année, un test du rapport de vraisemblance donne $p \approx 10^{-30}$. Autrement dit : la probabilité d'observer nos données si Poisson était vrai est de l'ordre d'un sur 10^{30}.

À dire à voix haute. *Poisson impose que la variance égale la moyenne. Sur les cellules firme-année, la variance dépasse la moyenne d'un facteur* 1,19 *: cela paraît peu, mais sur quinze mille cellules c'est un rejet à* 10^{-30}*. Donc j'ai changé de loi.*

Le piège. Ne pas dire « Poisson sous-estime le risque ». Poisson donne la *bonne* moyenne, il se trompe sur la *dispersion*, donc sur la queue. Le SCR est un quantile extrême : c'est la dispersion qui le fait, pas la moyenne.

6 La surdispersion et la négative binomiale

Le problème. Les données montrent beaucoup plus de variabilité que Poisson n'en autorise. Pourquoi, et comment en tenir compte ?

L'idée. Parce que le rythme lui-même varie. Certaines années sont plus exposées que d'autres, certaines entités plus que d'autres. On rend donc λ *aléatoire* au lieu de le fixer. Un mélange de Poisson par une loi Gamma donne exactement la négative binomiale.

La formule. Si $N \mid \Lambda \sim \mathcal{P}(\Lambda)$ et $\Lambda \sim$ Gamma, alors N est négative binomiale et

$$\mathbb{E}[N] = \lambda, \qquad \mathrm{Var}(N) = \varphi\,\lambda, \qquad \varphi > 1.$$

Le facteur φ est la **surdispersion** : le rapport variance sur moyenne.

Chez nous. L'indice de dispersion d'un mélange de Poisson vaut $1 + \lambda/r$: il n'est pas invariant d'échelle. Il vaut 1,19 sur les cellules firme-année, 2,24 sur la série annuelle détendancée, et le moteur retient $\varphi = 9{,}20$, choix de prudence posé et non mesure. Ce 9,20 et la charge systémique $a = 0{,}60$ du

modèle multi-états décrivent la même surdispersion agrégée à 5 % près ($a = 0{,}57$). À variance égale, la *forme* du mélange (Gamma ou lognormale) déplace encore la queue du nombre de 11 % (74 contre 82).

> **À dire à voix haute.** *La négative binomiale, c'est Poisson dont le rythme est lui-même incertain. Concrètement, certaines années sont plus exposées que d'autres, et ce sont ces années-là qui font le capital.*

Le piège. Le changement de loi de comptage **ne déplace pas la moyenne**, il déplace la VaR, et de +9 % seulement : à $\xi \approx 0{,}6$, le quantile annuel est porté par la perte unique dominante. Sur la série détendancée, la surdispersion mesurée (2,24) est quatre fois plus faible que celle retenue (9,20) : le calage est conservateur, pas calibré, et il faut le dire soi-même.

7 Pourquoi pas un processus de Hawkes

Le problème. Un processus auto-excité, où chaque événement augmente temporairement la probabilité du suivant, serait un candidat naturel pour de la contagion.

L'idée. Hawkes modélise la contagion *dans le temps* : un incident aujourd'hui rend un autre incident plus probable demain. Notre cascade modélise la contagion *entre domaines* : un incident sur un pilier rend un incident plus probable sur un autre pilier. Ce ne sont pas les mêmes axes.

Chez nous. Le test a été fait, sur la chronologie PRC datée, contre les noyaux de la littérature (Bessy-Roland, Boumezoued et Hillairet ; Boumezoued, Cherkaoui et Hillairet). L'excitation mesurée est intra-journalière, avec un pic à 3,3 heures, et le ratio de branchement de 0,551 tombe vers zéro dès que les co-occurrences du même jour sont traitées comme exogènes. Surtout, une cascade *sans aucune* auto-excitation, simulée puis ajustée comme une chronologie réelle, donne déjà 0,480 au jour : à la résolution disponible, les deux modèles ne sont pas distinguables.

> **À dire à voix haute.** *Hawkes décrit la contagion dans le temps, ma cascade décrit la contagion entre domaines. Je l'ai testé contre les noyaux de la littérature, et à la résolution des données il n'est pas distinguable d'une cascade sans auto-excitation. Je retiens la cascade par parcimonie, parce qu'elle porte en plus la structure entre piliers.*

Le piège. Ne pas dire que Hawkes est rejeté ou réfuté : c'est une équivalence observationnelle suivie d'un choix de parcimonie. Attention au sens : dégrader la résolution fait *monter* le ratio de branchement estimé. Et ne pas présenter ce choix comme une critique de cette littérature, qui travaille sur des données horodatées plus finement.

III. Combien coûte un incident

8 Pourquoi la théorie des valeurs extrêmes

Le problème. Le SCR est un quantile à 99,5 %. On veut donc décrire précisément la région où l'on a le moins d'observations. Ajuster une loi sur l'ensemble des données optimise l'ajustement là où il y a le plus de points, c'est-à-dire au *centre*, exactement là où l'on s'en moque.

L'idée. On abandonne l'idée d'une loi unique pour tout. On modélise *seulement* la queue, avec une famille dont on peut démontrer qu'elle est la seule limite possible.

> **À dire à voix haute.** *Une loi ajustée sur toutes les données est calée sur le centre, or je n'ai besoin que de la queue. La théorie des valeurs extrêmes dit quelle famille de lois est la seule possible tout au bout, et je n'ajuste que celle-là.*

9 Les deux théorèmes fondateurs

L'idée. Deux résultats, structurés exactement comme le théorème central limite : ils disent qu'*une seule* famille peut apparaître à la limite, quelle que soit la loi de départ.

La formule. **Fisher-Tippett-Gnedenko.** Si le maximum renormalisé de n variables indépendantes converge en loi, la limite ne peut être que la loi des valeurs extrêmes généralisée :

$$G_\xi(x) = \exp\Big\{-(1+\xi x)^{-1/\xi}\Big\}, \qquad 1+\xi x > 0.$$

Pickands-Balkema-de Haan. De façon équivalente, la loi des *excès* au-dessus d'un seuil u converge, quand u monte vers le point terminal, vers la loi de Pareto généralisée :

$$\mathbb{P}(X-u \le y \mid X > u) \;\longrightarrow\; 1-\left(1+\frac{\xi y}{\sigma}\right)^{-1/\xi}.$$

Chez nous. C'est le second qu'on utilise, parce qu'il exploite *tous* les dépassements de seuil et pas seulement le maximum de chaque bloc. On perd beaucoup moins d'information.

> **À dire à voix haute.** *C'est le même genre de résultat que le théorème central limite. Là où le TCL dit que les moyennes tendent vers une gaussienne quelle que soit la loi de départ, ces deux théorèmes disent que les extrêmes tendent vers une seule famille. Je n'ai donc pas* choisi *la loi de queue, elle est imposée.*

Le piège. Ces théorèmes sont *asymptotiques*. Ils ne garantissent pas que la GPD est correcte à un seuil fini : ils garantissent qu'aucune autre famille ne peut l'être à la limite. C'est plus faible, il faut le dire, et c'est pourquoi on teste l'adéquation.

10 La méthode des excès et la loi de Pareto généralisée

L'idée. On fixe un seuil u. En dessous, on garde la distribution empirique telle quelle. Au dessus, on ajuste une GPD. La loi obtenue est dite *recollée* (spliced).

La formule. La fonction de survie s'écrit, pour $x > u$:

$$\mathbb{P}(X > x) \;=\; p_u\left(1+\frac{\xi(x-u)}{\sigma}\right)^{-1/\xi}, \qquad p_u = \mathbb{P}(X>u).$$

Chez nous. $\xi = 0{,}5954$ sur OpRisk, $\xi = 1{,}03$ sur PRC. Le paramètre ξ est l'**indice de queue**, et il commande tout :

- $\xi < 1/2$: variance finie ;
- $1/2 \le \xi < 1$: variance *infinie*, moyenne finie : c'est le cas de la calibration publiée ;
- $\xi \ge 1$: moyenne elle-même infinie.

Le $\xi = 1{,}03$ de la PRC dépasse 1, mais il ne mesure pas un risque plus lourd : la sévérité PRC est une puissance du nombre d'enregistrements, et une puissance multiplie l'indice de queue par son exposant. C'est pourtant ce régime qui fait tomber la TVaR comme mesure de couverture : sous lui, elle n'existe pas.

> **À dire à voix haute.** *L'indice de queue mesure à quel point les catastrophes dominent. Sur ma calibration il vaut* 0,6 *: la variance des pertes est infinie, leur moyenne finie, et un seul sinistre peut peser plus que tous les autres réunis. C'est ce qu'on observe en cyber : sur OpRisk, le décile supérieur porte plus de* 92 % *de la perte totale.*

Le piège. Avec ξ proche de 1, la moyenne empirique n'est pas un estimateur stable et les intervalles de confiance sont larges par nature. Ne jamais annoncer un SCR ponctuel sans sa bande dans ce régime.

11 Le choix du seuil

Le problème. Le seuil u arbitre entre biais et variance : trop bas, on inclut le corps de la distribution et l'approximation GPD est fausse ; trop haut, il reste trop peu de points et l'estimation devient bruitée.

L'idée. On ne le choisit pas au hasard : on le lit sur des diagnostics, puis on vérifie qu'une règle écrite le retrouve.

La formule. **Vie résiduelle moyenne.** Pour une GPD, la fonction $e(u) = \mathbb{E}[X - u \mid X > u]$ est *linéaire* en u : on choisit u au début de la zone linéaire. **Diagnostic GPD.** On trace $\hat{\xi}$ en fonction de u : le seuil doit se situer là où ξ passe sous 1 (espérance finie) en gardant au moins trente excès.

Chez nous. Seuil retenu $u = 20{,}03$ M€ sur le périmètre cyber × finance d'OpRisk, soit 91 excès, et $p_u = 0{,}1509$, valeur gelée (le recomptage donnerait $91/582 = 0{,}1564$, écart chiffré au chapitre 11). Une règle de stabilité écrite, appliquée à dix percentiles candidats, retrouve 19,87 M€ avec le même quantile ; la règle la plus permissive descendrait à 12,88 et donnerait un quantile supérieur de 16 %. Attention : $\hat{\xi}$ n'est stable qu'au *voisinage* du seuil ; de 0,60 il descend à 0,38 quand on remonte au percentile 95, dans l'intervalle déjà publié.

Chez nous. **Complément après le dépôt (script 119, hors rapport).** Une règle de stabilité choisit un seuil ; un test d'adéquation le contrôle. J'ai calibré le test de Kolmogorov-Smirnov : la table usuelle est trop indulgente quand les paramètres sont estimés sur les données testées. La p-value vient donc d'un bootstrap paramétrique, où la GPD est réestimée sur chaque échantillon simulé (1 000 tirages par seuil, dix seuils de 8,62 à 105,39 M€). Au seuil retenu (91 excès), $D = 0{,}043$, $p = 0{,}938$ pour Kolmogorov-Smirnov et $p = 0{,}963$ pour Anderson-Darling. Seuls les deux seuils les plus bas (8,62 et 10,95) sont rejetés à 5 %, et par Anderson-Darling seulement. Au-dessus de 20 M€, $\hat{\xi}$ reste dans l'intervalle à 95 % de chaque seuil. Les quatre estimateurs au seuil retenu, avec leur intervalle à 95 % par bootstrap de 2 000 tirages des excès : maximum de vraisemblance 0,598 [0,250 ; 0,890], moments pondérés 0,507 [0,255 ; 0,622], moments de Dekkers, Einmahl et de Haan 0,864 [0,524 ; 1,081], Hill 1,377 [1,183 ; 1,585]. Le quantile de sévérité à 99,5 %, au taux gelé, vaut 642 [369 ; 1 091] par maximum de vraisemblance et 560 [360 ; 774] par moments pondérés. La méthode reprend la structure du mémoire de F. Dountio (test et bootstrap), pas ses valeurs : sa variable est un nombre de dossiers, la nôtre une perte en euros.

Le piège. Une p-value élevée à haut seuil peut venir du faible nombre d'excès, donc d'une puissance faible : le test écarte des seuils, il ne désigne pas un optimum. La sélection du seuil sur les mêmes données n'est pas corrigée. Et le réajustement sur la base courante donne $\hat{\xi} = 0{,}598$ et un quantile de 642, contre 0,595 et 663 publiés : les paramètres publiés viennent de l'échantillon 2000-2026 (86 excès).

> **À dire à voix haute.** *Le seuil se lit sur la vie résiduelle moyenne, qui devient droite au-delà de vingt millions, et une règle de stabilité écrite le retrouve à un pour cent près. Et il ne m'arrange pas : la règle la plus permissive donnerait un capital plus élevé.*

Le piège. Ne pas dire que le graphique de Hill confirme le seuil : Hill vaut 1,32 au seuil retenu, plus du double du maximum de vraisemblance, et le mémoire en fait une corroboration d'un autre genre, puisque c'est exactement ce que Hill produit en échantillon fini sous $\xi = 0{,}595$. Et ne pas confondre avec les 4,176 M€ d'une table descriptive : c'est le percentile 85 de la sévérité PRC dérivée, jamais un seuil.

IV. Comment les pertes s'additionnent

12 Le modèle collectif

L'idée. On ne modélise pas la perte annuelle directement. On modélise séparément *combien* d'incidents et *combien coûte* chacun, puis on somme. C'est le cadre standard en actuariat non-vie.

La formule.

$$L = \sum_{i=1}^{N} X_i,$$

avec N le nombre d'incidents (fréquence) et X_i leurs coûts (sévérité), les X_i indépendants de N et entre eux.

Chez nous. Des dizaines de milliers d'années simulées par Monte-Carlo, avec le bruit de simulation publié à côté de chaque grandeur. La loi de L n'a pas de forme fermée simple avec une queue lourde et une cascade, mais elle se calcule sans simuler par inversion de Fourier de sa fonction génératrice : c'est le contrôle du moteur, qui retrouve le quantile à moins d'une erreur type (5 945 contre 6 049 au conforme).

> **À dire à voix haute.** *Je sépare deux questions qui n'ont rien à voir : combien d'incidents par an, et combien coûte un incident. Chacune se calibre sur ses propres données, et la perte annuelle est leur somme.*

Le piège. L'indépendance entre N et les X_i est une hypothèse, et elle a été testée hors échantillon : elle tient sur les excès. La pente négative qu'on voit sur toute la distribution disparaît au-delà du seuil, c'est un artefact de profondeur de collecte. Et la cascade ne rend pas N et X dépendants : elle fait dépendre le coût d'un sinistre du nombre de piliers qu'il touche.

13 VaR, TVaR, et pourquoi le SCR est une VaR

L'idée. La VaR à 99,5 % est le montant qu'on ne dépasse que dans une année sur deux cents. La TVaR est la moyenne des pertes *au-delà* de ce seuil.

La formule.

$$\mathrm{VaR}_\alpha(L) = \inf\{x : \ \mathbb{P}(L \le x) \ge \alpha\}, \qquad \mathrm{TVaR}_\alpha(L) = \mathbb{E}[L \mid L > \mathrm{VaR}_\alpha(L)].$$

Chez nous. Solvabilité II impose la VaR à 99,5 % à horizon un an, et le mémoire la prend *non centrée* : la perte attendue d'une non-conformité n'étant couverte par aucune provision, elle n'est pas déduite. La TVaR sert de diagnostic, jamais de couverture : noyau de l'allocation d'Euler, et indicateur de forme, TVaR/VaR $\approx 2{,}1$ contre l'asymptote $1/(1-\xi) = 2{,}5$.

> **À dire à voix haute.** *Le capital, c'est la perte annuelle qu'on ne dépasse qu'une année sur deux cents. Ce n'est pas mon choix de mesure, c'est celui de Solvabilité II. La TVaR, je m'en sers pour diagnostiquer la queue, pas pour couvrir.*

Le piège. La VaR n'est pas sous-additive, la TVaR est cohérente : c'est vrai, et le mémoire ne dit pas le contraire. Mais l'argument décisif contre une couverture en TVaR n'est pas de degré, il est d'existence : sous la calibration PRC, $\xi = 1{,}03 > 1$, l'espérance est infinie et la TVaR n'existe pas. Une mesure de couverture qui cesse d'être définie selon la source ne peut pas porter un capital.

V. Comment un problème en entraîne un autre

14 La convention d'indices, à ne jamais improviser

Le problème. Une matrice dirigée a deux lectures possibles, et les deux sont défendables. Si le document en utilise l'une ici et l'autre là, tous ses énoncés directionnels deviennent ambigus.

L'idée. On fixe la convention une fois, on l'écrit, et on la vérifie sur un fait connu.

La formule.

$$W_{jk} \;=\; \text{propension de } j \text{ (\textbf{source}) à entraîner la défaillance de } k \text{ (\textbf{cible}).}$$

La **ligne** j décrit ce que j *émet*, la **colonne** k ce que k *reçoit*. La somme de ligne s_j mesure donc une **émission**.

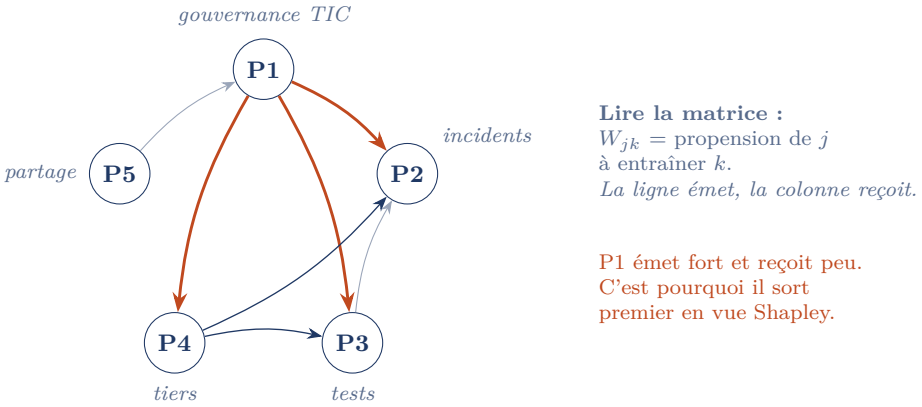
Chez nous. Vérification sur la matrice d'expert : P1 a la plus grande somme de ligne (2,6) et une somme de colonne trois fois inférieure à celle de P2. C'est exactement la revendication centrale « P1 émet fort et reçoit peu », et elle serait *fausse* sous la convention inverse. La forme réduite du modèle latent s'écrit alors $(I - W^{\top})^{-1}$, le rayon spectral étant de toute façon invariant par transposition.

> **À dire à voix haute.** *La ligne émet, la colonne reçoit. Je le vérifie sur ma matrice : le pilier que je dis émetteur a bien la plus grosse somme de ligne. Une convention n'est pas un détail de notation, c'est ce qui rend un énoncé directionnel falsifiable.*

Le piège. Ce défaut a réellement existé dans le mémoire : l'équation structurelle sommait sur les lignes alors que la définition de la cascade et tout le code sommaient sur les colonnes. Le code et le classeur ont tranché. Vérifier une convention sur un fait connu coûte trente secondes et évite une matrice transposée.

15 La matrice de contagion et sa normalisation

Le problème. On veut dire « un problème sur le pilier j aggrave le pilier k », avec une intensité. Mais si on met des coefficients au hasard, la cascade peut exploser.



La cascade est un *processus de branchement* : un incident amorcé sur un pilier tire, pour chaque arc, une pièce de Bernoulli de probabilité W_{jk}, et recommence depuis les piliers atteints. Sans garde-fou, ce processus peut ne jamais s'éteindre.

L'idée. On part du jugement dirigé (la matrice TRANS du classeur), et on la renormalise pour garantir mathématiquement que la propagation s'éteint.

La formule.

$$W \;=\; g\,\frac{T}{\max_j \sum_k T_{jk}}, \qquad g = 0{,}90,$$

ce qui garantit $\rho(W) \leq g < 1$, où ρ est le rayon spectral (la plus grande valeur propre en module).

Chez nous. Le facteur g est un curseur de propagation : $g = 0$ signifie aucune contagion, $g \to 1$ signifie une cascade au bord de l'explosion. On le fixe à 0,90, ce qui est volontairement élevé.

> **À dire à voix haute.** *La normalisation garantit que la cascade s'éteint. Sans elle, un choc pourrait s'amplifier indéfiniment en tournant en boucle entre les piliers, et le capital serait infini.*

Le piège. Les valeurs de g, 0,45 au conforme, 0,68 au partiel et 0,90 au non conforme, sont des *choix*, pas des mesures. À dire ainsi : « elles sont posées, mais la signe est conservé sur les cinq correspondances testées et sur la grille en g, avec la cascade indépendante. Cette vérification ne démontre pas la monotonie pour toute valeur de g, ni pour tous les moteurs. L'amplitude reste un scénario ».

16 L'inverse de Leontief et la sous-criticité

L'idée. Le choc initial se propage, ce qu'il déclenche se propage à son tour, et ainsi de suite. La somme de tous les tours est une série géométrique matricielle.

La formule.

$$(I - W)^{-1} \;=\; I + W + W^2 + W^3 + \cdots$$

Cette série converge *si et seulement si* $\rho(W) < 1$. Le terme I est le choc initial, W ce qu'il déclenche directement, W^2 ce que cela déclenche à son tour.

Chez nous. L'objet vient de l'économie (Leontief, tableaux entrées-sorties) : la même algèbre décrit comment une commande dans un secteur en génère dans les autres. Sur la matrice du mémoire, $\rho(W) = 0{,}562\,g$, soit 0,506 à $g = 0{,}9$; le seuil critique $\rho(W) = 1$ serait atteint à $g = 1{,}78$, hors du domaine admissible.

> **À dire à voix haute.** *C'est la même formule que les tableaux entrées-sorties en économie. Le premier terme est le choc direct, le deuxième ce qu'il déclenche, le troisième ce que cela déclenche à son tour. La condition de convergence est exactement la condition pour que la cascade s'éteigne.*

Le piège. Le passage à W^2 est celui où la *direction* commence à compter, alors qu'elle ne compte pas dans W seul si on ne regarde que les co-occurrences. C'est le point technique le plus important du mémoire, voir la section 28.

17 Le seuil de déclenchement, et le rôle de la loi normale

Le problème. À partir de quand un pilier bascule ? Il faut un mécanisme, pas seulement une probabilité.

L'idée. On suppose une variable latente X_j qui mesure la fragilité du pilier j, et le pilier bascule quand elle franchit un seuil. C'est le mécanisme de Merton, repris par Vasicek pour le risque de crédit.

La formule. Le pilier j bascule quand

$$X_j \;\geq\; K_j \;=\; F^{-1}(1 - p_j),$$

où p_j est sa probabilité marginale de basculement et F la fonction de répartition de la latente.

Chez nous. $K_4 = 1{,}03$ pour le pilier des prestataires, dont la probabilité de déclenchement vaut $p_4 = 0{,}151$.

À dire à voix haute. *Il y a deux questions derrière le mot seuil, et il ne faut pas les mélanger. Pour savoir* quand un pilier bascule tout seul*, la loi normale est inoffensive : elle ne sert que d'unité de mesure, la vraie queue lourde est dans la sévérité, pas ici. Pour savoir* combien de piliers basculent ensemble*, c'est autre chose, et là le gaussien pose un vrai problème.*

Chez nous. Un seuil par entité ? Le cadre général est $K_{ij} = F_{ij}^{-1}(1 - p_{ij})$: i est l'entité, j le pilier, F_{ij} la loi du stress latent et p_{ij} la probabilité cible de dépassement. Écrire F_i seul suppose la même marge pour les cinq piliers d'une entité, ce que la propagation ne garantit pas. Avec des chocs gaussiens, $\sigma_{ij}^2 = [(I - W^\top)^{-1}\Sigma_i(I - W)^{-1}]_{jj}$ et $K_{ij} = \sigma_{ij}\Phi^{-1}(1 - p_{ij})$. L'écriture est possible ; l'estimation ne l'est pas : aucune base n'observe la perte par pilier ni par entité, et un écart de 0,10 sur une sensibilité demande environ 813 périodes. Le mémoire garde donc un seuil K_j commun, et le capital passe par la cascade, une sévérité commune puis la descente d'échelle.

Le piège. À probabilités et dépendance inchangées, transformer ensemble une marge et son seuil ne change aucun déclenchement. Changer F_i ne personnalise donc rien : il faudrait des p_{ij} différents, une autre dépendance, ou une autre loi de perte. Et cette loi latente, sans unité, ne remplace pas la GPD des sévérités en euros.

Le piège. Le choix de la loi de la latente est une *normalisation* pour la marge : n'importe quelle loi continue donnerait la même probabilité marginale, seul le seuil change de valeur. Ce n'est pas vrai pour la dépendance. Confondre les deux est l'erreur classique.

18 Les copules et la dépendance de queue

Le problème. Comment plusieurs piliers basculent-ils *ensemble* ? La probabilité marginale de chacun ne suffit pas à le dire.

L'idée. Une copule sépare les marges de la structure de dépendance. On peut garder les mêmes marges et changer complètement la façon dont les événements extrêmes se coordonnent.

La formule. Le coefficient de **dépendance de queue supérieure** mesure la co-occurrence extrême :

$$\lambda_U \;=\; \lim_{q \to 1^-} \; \mathbb{P}(U_2 > q \mid U_1 > q).$$

Pour la copule gaussienne, $\lambda_U = 0$ dès que la corrélation est < 1. Pour la copule de Gumbel de paramètre θ,

$$\lambda_U \;=\; 2 - 2^{1/\theta}.$$

Chez nous. Avec $\theta = 1{,}8$, on a $\lambda_U = 0{,}53$. À τ de Kendall *égal*, la gaussienne donne 0 et Gumbel 0,53. La probabilité que les cinq piliers basculent ensemble passe de 0,17 à 0,39 selon la copule retenue. On encadre au lieu de trancher : plancher gaussien, plafond de Gumbel. Le co-déclenchement d'un autre pilier avec P4 tient alors dans [0,48 ; 0,58], sous la borne $\gamma = 0{,}68$ du choc commun, qui reçoit ainsi son origine structurelle.

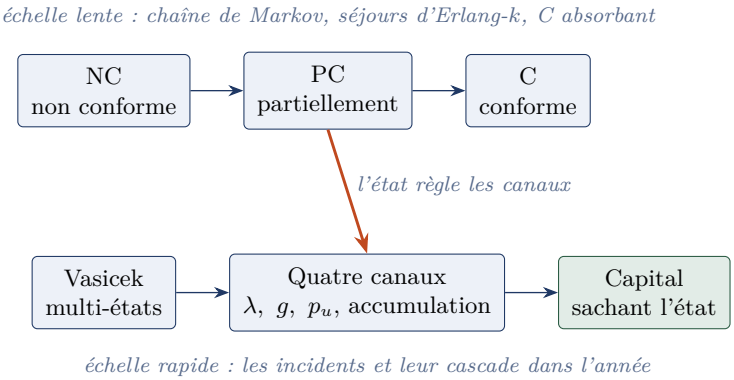
À dire à voix haute. *Une dépendance gaussienne a une propriété gênante : dans les extrêmes, elle prédit que les choses se* découplent*. C'est le contraire de ce qu'on observe en crise. Donc je n'ai pas tranché entre les deux, j'ai encadré, et l'écart entre le plancher et le plafond est un résultat en soi.*

Le piège. Deux copules peuvent avoir le *même* τ de Kendall, donc la même dépendance « moyenne », et des comportements extrêmes opposés. Comparer deux copules par leur corrélation ne dit rien sur la queue.

19 Les états de conformité : Vasicek à l'échelle rapide, Markov à l'échelle lente

Le problème. Être conforme à DORA n'est ni un oui ni un non, et cela change avec le temps. Comment mettre un état de conformité dans un modèle de capital, sans le figer et sans le réduire à un interrupteur ?

L'idée. On sépare deux horloges. À l'échelle *rapide*, celle des incidents et de leur cascade dans l'année, l'état de conformité est une photographie : chaque pilier est non conforme (NC), partiellement conforme (PC) ou conforme (C), et le moteur calcule le capital *sachant* cette configuration. Cet état est tiré par un Vasicek. À l'échelle *lente*, celle des mois et des années, une chaîne de Markov fait progresser la conformité, et son état règle les paramètres de la couche rapide. On sépare les deux pour qu'une tendance longue n'explique pas un enchaînement de quelques heures.



La formule. D'où vient le seuil. Merton pose qu'un défaut survient quand une variable latente franchit un seuil. Vasicek y ajoute un facteur commun, qui crée la dépendance :

$$X_i \;=\; \sqrt{\rho}\,Y + \sqrt{1-\rho}\,\varepsilon_i, \qquad \text{défaut si } X_i \geq K_i = \Phi^{-1}(1-\mathrm{PD}_i).$$

Notre version, à trois états. Chaque pilier a une capacité de conformité latente, décomposée à la Vasicek en un facteur systémique Θ et un choc propre :

$$C^\star \;=\; \gamma\,\Theta + \sqrt{1-\gamma^2}\,\varepsilon, \qquad \gamma = 0{,}68.$$

Au lieu d'un seuil de défaut, on en pose deux, ordonnés, $K_{\text{bas}} < K_{\text{haut}}$:

$$\text{NC si } C^\star \leq K_{\text{bas}}, \qquad \text{PC si } K_{\text{bas}} < C^\star \leq K_{\text{haut}}, \qquad \text{C si } C^\star > K_{\text{haut}},$$

avec $K_{\text{bas}} = \Phi^{-1}(p_{NC})$ et $K_{\text{haut}} = \Phi^{-1}(p_{NC}+p_{PC})$. C'est un probit ordonné. Sachant l'environnement Θ :

$$\mathbb{P}(\text{NC} \mid \Theta) = \Phi\Big(\tfrac{K_{\text{bas}}-\gamma\Theta}{\sqrt{1-\gamma^2}}\Big), \qquad \mathbb{P}(\text{C} \mid \Theta) = 1-\Phi\Big(\tfrac{K_{\text{haut}}-\gamma\Theta}{\sqrt{1-\gamma^2}}\Big).$$

Chez nous. Les probabilités d'état sont ancrées sur les enquêtes de conformité de fin 2025 : NC 35 %, PC 35 %, C 30 %. Les cinq piliers partagent Θ avec la charge $\gamma = 0{,}68$, soit une corrélation $\gamma^2 = 0{,}462$ entre deux piliers quelconques. En crise systémique (Θ très négatif), la masse bascule vers la non-conformité. L'état agit ensuite par quatre canaux : la fréquence λ passe de 21,56 à 53,62 incidents par an, le gain de propagation g de 0,45 (C) à 0,68 (PC) puis 0,90 (NC), le taux de matérialité p_u est multiplié par 0,85 (C) ou 1,20 (NC), et l'accumulation par un prestataire commun apparaît à l'état NC, avec une charge de 0,68.

La formule. L'échelle lente. Une chaîne de Markov à temps continu NC → PC → C, dont l'état conforme est absorbant dans le cas de base. Les séjours sont de type phase (Erlang-k) : une exponentielle autoriserait une remédiation quasi instantanée, alors qu'un projet DORA a une durée minimale. Avec Q le générateur et v_0 la distribution initiale,

$$\big(\mathbb{P}(\text{NC},t),\,\mathbb{P}(\text{PC},t),\,\mathbb{P}(\text{C},t)\big) \;=\; v_0\,e^{Qt} \text{ (sommes de phases)}, \qquad \mathrm{SCR}(t) \;=\; \sum_{e\in\{\text{NC,PC,C}\}} \mathbb{P}(e,t)\,\mathrm{SCR}_e.$$

Le couplage. Le même Θ agit sur les deux couches : un environnement dégradé ralentit la remédiation, $\mu(\Theta) = \mu_0\, e^{\beta_{\text{rem}}\Theta}$, et durcit la cascade, $\text{SCR}_e(\Theta) = \text{SCR}_e\, e^{-\beta_{\text{casc}}\Theta}$. La dispersion de Θ engendre la bande d'incertitude de la trajectoire.

Chez nous. De l'état marginal actuel (NC 35 %, PC 35 %, C 30 %), le capital OpRisk passe de 10 752 à 7 041 M€ en cinq ans. La formule $\text{SCR}(t)$ est une moyenne de quantiles : elle diffère du quantile à 99,5 % de la loi mélangée, de 9,3 % sur le mélange des 32 configurations. La trajectoire se lit donc comme l'espérance du besoin de capital sous l'incertitude d'état.

> **À dire à voix haute.** *À l'échelle rapide, l'état de conformité est un probit ordonné à la Vasicek : une capacité latente et deux seuils qui découpent trois états. À l'échelle lente, une chaîne de Markov le fait progresser de NC à C, et son état règle les quatre paramètres du moteur. Le seuil vient de Merton, le facteur commun de Vasicek, la migration d'état du risque de crédit : la chaîne joue le rôle de la migration d'un rating de conformité, le Vasicek celui du défaut conditionnel au rating.*

Le piège. **Deux latentes de sens opposé.** Dans la cascade, X mesure le *stress* : un X élevé est une mauvaise nouvelle. Ici $C^\star$ est une *capacité* : élevée, elle est bonne, et la non-conformité est en bas. Le facteur Θ de conformité n'est pas non plus le facteur Y_j par pilier de la cascade.

Le piège. **Les trois valeurs de g sont posées**, parce que l'état de conformité DORA des entités n'est pas publié. La cascade indépendante respecte l'ordre du capital sur la grille de vingt points et les cinq correspondances testées. Cela ne démontre ni une monotonie pour tout g ni la même propriété pour le moteur de marche. L'écart « 116 à 169 M€ » reste conditionnel aux valeurs posées.

Le piège. La loi d'Erlang est *posée*. Elle n'a aucun rapport avec la loi mélangeante de la fréquence du chapitre sur le modèle fréquence-sévérité, dont la forme estimée est 0,63. Et les données ne mesurent pas le niveau de conformité d'une entité : c'est pourquoi l'état est supposé, jamais observé.

VI. Ce qu'on ne peut pas savoir, et pourquoi

20 La décomposition $W = S + A$

L'idée. Toute matrice se coupe de manière unique en une partie symétrique et une partie antisymétrique. La première dit *qui est lié à qui*, la seconde dit *dans quel sens*.

La formule.

$$S = \tfrac{1}{2}(W + W^\top), \qquad A = \tfrac{1}{2}(W - W^\top), \qquad W = S + A.$$

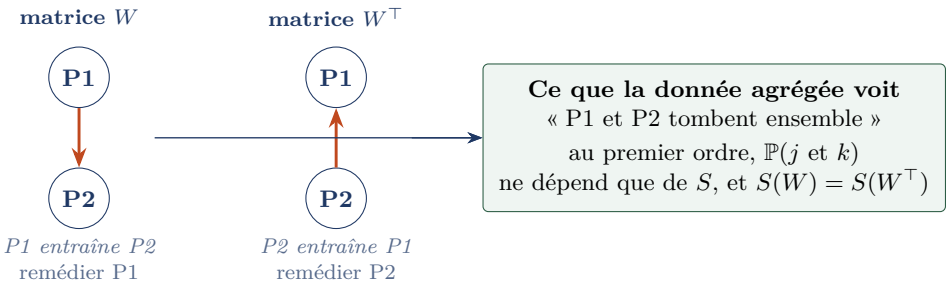
Les deux parties sont **orthogonales** : $\langle S, A\rangle = 0$, d'où un Pythagore $\|W\|^2 = \|S\|^2 + \|A\|^2$.

Chez nous. Sur la matrice ordonnée estimée à partir du corpus de rapports, la part de direction $\|A\|/\|W\|$ vaut 60 %, et elle ne bouge pas quand on corrige le dénominateur, alors que le niveau des p_{jk} tombe de 0,27 à 0,07. La direction n'est pas un détail de la matrice.

> **À dire à voix haute.** *On coupe la matrice en deux : une partie qui dit quels piliers sont liés, et une partie qui dit dans quel sens. Les deux sont orthogonales, et la co-occurrence que voit la donnée ne dépend, au premier ordre, que de la première.*

Le piège. La décomposition propre porte sur le *flux stationnaire* $\pi_j P_{jk}$, pas sur la matrice de transition brute. Notre $S = (W + W^\top)/2$ en est le cas où π est uniforme, et l'écart mesuré est de 0,069, donc faible. Le dire soi-même met à l'abri.

Le schéma qui fait comprendre la thèse en dix secondes. Deux matrices opposées, une seule statistique observable, deux décisions contraires.



Indiscernables pour la donnée. Matériellement différentes pour la décision.

C'est l'énoncé de la frontière d'identification, et il ne repose sur *aucun* dire d'expert : au premier ordre et sous amorce uniforme, la co-occurrence est une fonction de S seule, et S est identique pour W et pour sa transposée. Ce n'est pas une impossibilité de principe : au-delà du premier ordre, la loi complète des piliers touchés par incident distingue W de $W^\top$, une fourche d'un collisionneur (62,31 % de sinistres multi-piliers sous W, 50,77 % sous $W^\top$). La frontière est celle des statistiques que les sources fournissent, et c'est pourquoi le registre recommandé consigne tous les piliers touchés.

21 Le renversement du temps et la fluctuation martingale

Le problème. Pourquoi n'arrive-t-on pas à mesurer A ? Et est-ce une limite de méthode ou une limite de principe ?

L'idée. Passer le film à l'envers. La partie symétrique ne change pas, la partie antisymétrique s'inverse. Et la fluctuation d'un processus, une fois la tendance retranchée, ne dépend que de la première.

La formule. La chaîne renversée a pour flux $F^* = F^\top = S - A$. Et pour toute fonction test f, l'intensité de la fluctuation vaut

$$\mathbb{E}_\pi[\Gamma(f,f)] \;=\; \sum_{j,k} S_{jk}\big(f(k)-f(j)\big)^2,$$

la partie A y contribuant exactement zéro. La démonstration tient en une ligne : $(f(k)-f(j))^2$ est symétrique en (j,k), A est antisymétrique, les termes (j,k) et (k,j) se compensent.

Chez nous. Vérifié sur trois cents fonctions test tirées au hasard : l'énergie de fluctuation est la même pour la chaîne posée et pour sa symétrisée, les points tombent sur la diagonale (figure du chapitre 8, § 8.3).

> **À dire à voix haute.** *Renverser le temps laisse la partie symétrique intacte et retourne le signe de la partie directionnelle. Or la fluctuation d'un processus, sa partie martingale, ne dépend que de la symétrique. Donc une statistique invariante par renversement du temps ne peut pas voir la direction. La loi complète des piliers touchés par incident, elle, le pourrait : c'est une donnée qui manque, pas une impossibilité.*

Le piège. Ne pas dire que W *est* une chaîne de Markov. C'est un noyau de contagion : on emprunte l'algèbre de la réversibilité comme cadre de lecture, on n'ajoute pas une hypothèse. Et le mot martingale s'entend au sens des chaînes de Markov, sous la mesure physique : aucune mesure risque-neutre, aucun test de martingalité.

22 Le test placebo

Le problème. Même des données sans aucune direction produisent un déséquilibre, par simple fluctuation d'échantillonnage. Observer un déséquilibre ne prouve donc rien tant qu'on ne sait pas ce que le hasard produit tout seul.

L'idée. On fabrique une version des données dont la direction a été **détruite volontairement**, tout le reste étant conservé, et on compare. C'est l'essai clinique : si le médicament ne fait pas mieux que la pilule vide, il ne fait rien.

La formule. On mesure l'asymétrie de la matrice de transitions comptées :

$$\mathcal{A}(M) = \frac{\|M - M^\top\|_1}{2} = \frac{1}{2}\sum_{j,k}|M_{jk} - M_{kj}|,$$

c'est-à-dire le surplus de transitions d'un sens sur l'autre, sommé sur toutes les paires. Puis on **permute les années à l'intérieur de chaque entité** : l'ensemble des catégories touchées chaque année est conservé, seul l'ordre est détruit. On recompte, on recalcule, et on compare :

$$z = \frac{\mathcal{A}(M_{\text{obs}}) - \overline{\mathcal{A}^{\text{null}}}}{\widehat{s}(\mathcal{A}^{\text{null}})}.$$

Chez nous.

Source	observée	sous placebo	z	Verdict
OpRisk, pas annuel	119	128 ± 27	$-0{,}33$	aucun signal
7 post-mortems	*même protocole*		$+3{,}93$	signal net

Sur OpRisk, l'observé est *sous* la moyenne du bruit. Un test binomial par paire le confirme : aucune paire ne survit à la correction de Bonferroni.

> **À dire à voix haute.** *Je voulais savoir si la direction que je crois voir est réelle. Le problème, c'est que même des données au hasard produisent un déséquilibre. Alors j'ai pris mes données, j'ai détruit l'ordre en gardant tout le reste, et j'ai comparé. Mes vraies données font* 119*, le hasard fait* 128 *: elles font moins bien que le hasard. Puis j'ai refait exactement le même test sur les sept rapports d'enquête, et là le signal apparaît nettement. Même test, autre source, résultat opposé : le problème venait de la donnée, pas de la méthode.*

Le piège. Trois choses à ne pas dire. **(i)** Le test du « temps inversé » est *dégénéré* sur un comptage : renverser la chronologie donne $M^\top$ par construction, donc une corrélation de -1 quel que soit le contenu. Il ne prouve rien. **(ii)** Un test non rejeté n'est pas une preuve d'absence : la donnée est *compatible* avec l'absence de direction. **(iii)** Sur les post-mortems, le test établit la *cohérence* du codage, pas son *exogénéité* : le biais de narration des rapports d'enquête n'est pas levé par le calcul.

23 La production d'entropie

L'idée. Un seul nombre qui dit à quel point le processus est dirigé, et qui a une interprétation exacte : à quel point le film à l'endroit est distinguable du film à l'envers.

La formule.

$$\sigma = \sum_{j<k} 2A_{jk}\,\ln\frac{S_{jk} + A_{jk}}{S_{jk} - A_{jk}} \;\geq\; 0,$$

nulle si et seulement si $A = 0$. Elle est aussi le taux d'entropie relative entre la loi de la trajectoire lue à l'endroit et celle lue à l'envers.

Chez nous. σ est strictement positive pour la chaîne posée et s'annule à la symétrisation (figure du chapitre 8, § 8.3). **Et la conséquence qui compte**, qui se lit sur la formule : chaque terme de la somme est *pair* en A_{jk}, donc σ ne dépend que des *amplitudes* de la direction, pas de ses signes. Les 1 024 sommets de l'ensemble admissible, qui ne diffèrent que par les signes, ont donc la même production d'entropie, alors que le capital y varie d'un facteur 1,27.

À dire à voix haute. *La production d'entropie mesure à quel point on peut distinguer le film à l'endroit du film à l'envers. Si elle est nulle, personne ne peut dire dans quel sens le temps coule. Mais attention : elle ne voit que la* quantité *de direction, jamais son* sens*. Les mille vingt-quatre configurations ont la même production d'entropie, et pourtant elles étalent le capital de plus d'un quart.*

Le piège. Conséquence à tirer : ce n'est pas σ qu'il faut chercher à estimer, ce sont les *signes*, un par un. C'est ce qui justifie que la valeur d'information se hiérarchise par paire et non globalement.

24 z scalaire ou z par paire

Le problème. L'écriture $P = S + zA$ est ambiguë tant qu'on n'a pas dit si z est un nombre ou dix.

La formule. **Lecture globale** : $z \in [-1, 1]$ règle l'*intensité* d'un motif de direction fixé. Un seul degré de liberté. Elle ne peut pas changer quel pilier précède quel autre. **Lecture par paire**, celle du mémoire :

$$A_{jk} = z_{jk}\, t\, S_{jk}, \qquad z_{jk} \in [-1, 1], \qquad j < k,$$

soit **dix degrés de liberté**. Le paramètre t est l'amplitude maximale d'asymétrie, les z_{jk} portent chacun un sens indépendant.

Chez nous. Les $2^{10} = 1024$ sommets sont exactement les configurations $z_{jk} = \pm 1$. La contrainte de positivité du flux impose $|A_{jk}| \leq S_{jk}$, donc $t \leq 1$; $t = 1$ est l'ignorance totale.

À dire à voix haute. *Un z global ne fait que renforcer ou affaiblir un ordre déjà choisi. Ce qu'il me faut, c'est un curseur par paire, parce que c'est le* sens *de chaque lien que je ne connais pas, pas son intensité globale.*

25 Le troisième échec : le schéma existe, il n'est pas rempli

Le problème. Deux bases ont échoué à identifier la direction, l'une faute de taxonomie, l'autre faute de résolution temporelle. On pouvait encore croire que personne n'avait *prévu* de collecter la bonne donnée.

L'idée. On teste l'hypothèse la plus favorable : un standard de description d'incidents qui, lui, prévoit exactement les bons champs. Le schéma VERIS, référence de la profession et support du *Data Breach Investigations Report*, porte littéralement les deux objets manquants : un champ `control_failure` qui nomme le domaine de contrôle défaillant, et une chronologie en quatre étapes qui porte l'antériorité.

Chez nous. Sur les 10 591 incidents de la base publique associée : `control_failure` renseigné dans 0,12 % des cas (13 incidents, dont un seul en secteur financier), chronologie datée sur au moins deux étapes dans 1,19 %. Et l'**intersection** des deux, qui est ce qu'identifier W exigerait simultanément, ne compte qu'**un seul incident**, et **aucun** en secteur financier.

À dire à voix haute. *Le champ qui donnerait la réponse existe dans le standard de la profession. Il est rempli treize fois sur dix mille incidents. Le problème n'est donc pas de savoir quoi collecter, il est d'en rendre le remplissage obligatoire, et c'est précisément ce qu'un régime de notification réglementaire peut imposer là où une base déclarative volontaire ne le peut pas.*

Le piège. C'est le plus utile des trois échecs, parce qu'il transforme la recommandation. On ne demande plus d'inventer une taxonomie, ce qui serait long et contestable, on demande de rendre obligatoires deux champs **déjà normalisés**. Coût de conception nul.

26 La matrice ordonnée p_{jk}

Le problème. Le codage documentaire, tel qu'on l'exploite d'abord, compare $n(j \to k)$ à $n(k \to j)$ *à l'intérieur* d'une paire. Ce rapport élimine le dénominateur, donc il donne un *sens* et ne dit rien de l'*amplitude*.

L'idée. On ajoute le dénominateur. Chaque incident déclare non seulement ses transitions, mais l'ensemble des **piliers défaillants**, y compris ceux qui ont cédé sans rien entraîner. On peut alors estimer directement chaque case de la matrice ordonnée.

La formule. Avec N_j le nombre d'incidents où j a cédé et m_{jk} ceux où le rapport établit $j \to k$:

$$p_{jk} = \mathbb{P}(k \text{ cède} \mid j \text{ a cédé}), \qquad p_{jk} \mid \text{données} \;\sim\; \mathrm{Beta}(1 + m_{jk},\; 1 + N_j - m_{jk}).$$

C'est la matrice ordonnée *complète*, donc S **et** A.

Chez nous. Sur dix rapports et 22 transitions : **douze** liens sur vingt ont un crédible à 90 % entièrement *sous* 0,5, et **aucun** au-dessus. Les plus élevés, $P_3 \to P_2$ (0,77, [0,48 ; 0,95]) et $P_1 \to P_4$ (0,68, [0,40 ; 0,89]), recouvrent encore 0,5. Les douze liens faibles comprennent les *quatre* sorties de P_2, soit toutes, et trois des quatre entrées de P_1, l'arc $P_5 \to P_1$ n'étant pas établi comme faible : le puits est établi comme tel, la source pure seulement en partie.

> **À dire à voix haute.** *Mon corpus établit très bien où la contagion* ne va pas*, et pas du tout où elle va fort. Le puits et la source pure sont donc établis en tant que tels, mais aucun coefficient n'est établi comme grand. C'est un ordre, ce n'est pas une magnitude.*

Le piège. Une enquête raconte la *chaîne* qui a produit le sinistre : elle documente bien les contrôles qui ont cédé *et* propagé, mal ceux qui ont cédé sans propager, pas du tout ceux qui ont tenu. Le dénominateur N_j est donc sous-estimé et p_{jk} est une **borne supérieure**. En ajoutant des défaillances non propagées, le *niveau* s'effondre de 0,27 à 0,07 tandis que la part de direction $\|A\|/\|W\|$ ne bouge pas (60 %). Le corpus établit un ordre, pas une magnitude, et cette phrase-là est robuste.

27 L'identification partielle

L'idée. Quand la donnée ne détermine pas un paramètre, on peut étudier les résultats compatibles avec un ensemble d'hypothèses déclaré. Ici, la partie symétrique S est posée à dire d'expert ; seule la direction varie. L'exploration numérique est donc conditionnelle à ce choix.

La formule. On définit l'ensemble admissible

$$\mathcal{W} = \{\, W = S + A \;:\; |A_{jk}| \le t\, S_{jk} \,\},$$

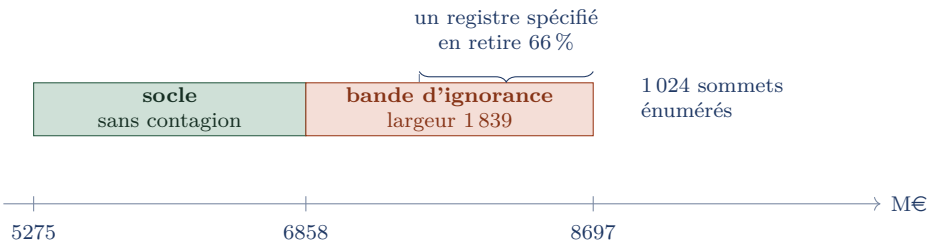
et l'on rapporte $[\inf_{\mathcal{W}} \mathrm{SCR},\; \sup_{\mathcal{W}} \mathrm{SCR}]$ au lieu d'un point.

Chez nous. Socle sans contagion 5 275 M€. Avec contagion et ignorance totale, plage calculée aux sommets dans [6 858 ; 8 697] M€, un facteur 1,27 : la contagion ajoute entre +30 et +65 % au socle. L'énumération porte sur 1 024 sommets, et 3 000 points intérieurs tirés au hasard ne sortent pas de l'enveloppe des sommets, ni en VaR ni en perte moyenne (bornée dans [849 ; 1 100]). Le point d'expert, 8 110, est un point de l'ensemble, jamais sa mesure.

> **À dire à voix haute.** *Je ne prétends pas connaître la direction, donc je ne donne pas un chiffre, je donne une fourchette. Ce n'est pas de la prudence, c'est la seule réponse possible : une grandeur qui compte pour le résultat et qui est invisible dans mes données.*

Le piège. L'atteinte des extrêmes aux sommets est une *propriété vérifiée numériquement*, pas un théorème démontré. C'est déclaré comme telle dans le mémoire.

Le schéma à projeter si l'on vous demande « quel est votre SCR ».



La largeur de la bande n'est pas une incertitude subie : c'est une grandeur **calculée à l'avance**, et le mémoire dit combien elle se réduirait si telle donnée existait. C'est ce qui transforme une limite en livrable.

28 Pourquoi A compte quand même

Le problème. Si A est invisible dans la donnée, pourquoi s'en soucier ?

La formule. Parce que le capital passe par $(I-W)^{-1} = I+W+W^2+\cdots$, et dès le terme quadratique $W^2 = S^2 + SA + AS + A^2$ fait apparaître A. En prenant la trace :

$$\operatorname{tr}(W^2) \;=\; \|S\|^2 - \|A\|^2.$$

Le signe moins vient de l'antisymétrie : $A^\top = -A$ implique $A^2 = -AA^\top$.

> **À dire à voix haute.** *La direction est invisible au premier ordre mais elle apparaît dès qu'on met la matrice au carré, et le calcul du capital passe par là. Une grandeur qui compte pour la réponse et qui est absente de la donnée : c'est la définition exacte d'une identification partielle.*

VII. À quel point on y croit

29 Le bootstrap

L'idée. On ne connaît pas la loi de l'estimateur. Alors on la fabrique : on rééchantillonne les données avec remise, on réestime à chaque fois, et la dispersion des estimations obtenues approche la dispersion vraie.

Chez nous. L'intervalle de confiance bootstrap du quantile de sévérité à 99,5 %, [411 ; 1 037] M€, vaut un **facteur** 2,5 entre ses deux bouts. Le bootstrap est aussi utilisé en version *paramétrique* pour les tests d'adéquation : on simule sous la loi ajustée pour obtenir la loi de la statistique de test.

> **À dire à voix haute.** *Le bootstrap fabrique la loi de mon estimateur en rééchantillonnant mes propres données. Et le résultat est brutal : rien que cette incertitude-là vaut un facteur deux et demi sur le quantile d'un sinistre, et près de neuf sur la charge annuelle.*

Le piège. Le bootstrap capture l'incertitude *de paramètre* à modèle fixé. Il ne dit rien du risque que le modèle lui-même soit faux. Et le facteur 2,5 porte sur le quantile d'*un* sinistre : porté sur la charge annuelle, le même intervalle de ξ donne un facteur 8,93. Ne jamais comparer tel quel ce 2,5 à un facteur lu sur la charge annuelle.

30 Les tests d'adéquation

L'idée. Une loi ajustée peut être fausse. On teste la distance entre la loi ajustée et les données, et on regarde si cette distance est anormalement grande.

La formule. Kolmogorov-Smirnov mesure l'écart maximal entre les fonctions de répartition. Anderson-Darling pondère ce même écart pour donner davantage de poids aux *queues*, ce qui est exactement la région qui nous intéresse.

Chez nous. Par bootstrap paramétrique : Anderson-Darling $p = 0{,}96$ et Kolmogorov-Smirnov $p = 0{,}89$ pour la famille GPD ; avec les paramètres publiés imposés, 0,99 et 0,89, ce qui atteste le chiffre et pas seulement le choix de loi. La couverture réelle de l'intervalle à 90 % de ξ vaut 86 % : l'intervalle est *trop étroit*, et il faudrait élargir sa demi-largeur d'environ 10 %. La binomiale négative bat Poisson avec $p \approx 10^{-30}$.

À dire à voix haute. *Les tests ne rejettent pas, avec des valeurs p de* 0,89 *à* 0,99. *Attention à ce que cela veut dire : les* formes *ne sont pas rejetées, mais c'est le* niveau *qui reste une bande, et la couverture des quantiles de sévérité est, elle, rejetée hors échantillon.*

Le piège. Les valeurs critiques tabulées de KS et AD sont fausses quand les paramètres sont *estimés* sur les mêmes données. Il faut passer par un bootstrap paramétrique, ce que nous faisons, et il faut le dire, parce que beaucoup de mémoires ne le font pas.

31 Les trois étages d'incertitude

L'idée. L'incertitude ne se réduit pas à l'intervalle de confiance. Elle a trois sources qui se cumulent et dont les tailles n'ont rien à voir.

Chez nous.

Étage, sur la charge annuelle	Ce qui varie	Bande (M€)	Facteur
Paramètre	ξ sur son intervalle à 90 %	[3 042 ; 27 152]	8,93
Identification	la direction, non identifiée	[6 858 ; 8 697]	1,27
Modèle, dépendance	de l'indépendance au comonotone	[5 322 ; 9 806]	1,84
Modèle, famille de queue	de la lognormale à la queue lourde	[4 330 ; 39 901]	9,21

À dire à voix haute. *Lues sur la même grandeur, la charge annuelle, l'incertitude de paramètre et celle de modèle sont du même ordre, un facteur de l'ordre de neuf chacune, et elles écrasent celle de l'identification. La bande que je reporte cumule le paramètre et l'identification ; le choix de famille, qui ne se moyenne pas, est publié comme axe de sensibilité. Et le résultat qui tient est ailleurs :* ***le niveau bouge dans la bande, l'ordre d'amorce des piliers ne bouge pas d'une famille à l'autre.***

Le piège. Deux fautes à éviter. Comparer le facteur 2,5 du quantile d'un sinistre au facteur 5,5 de la famille de queue (lognormale 4 330 contre GPD à $\xi = 0{,}90$, 24 016) : ce sont deux échelles. Et laisser croire que rien ne tient : toujours enchaîner avec les tests d'adéquation et l'invariance de l'ordre. Les largeurs de paramètre font varier ξ seul : elles ne sont ni des intervalles conjoints ni des majorants garantis de l'incertitude totale.

32 VaR prédictive et VaR robuste

Le problème. La remarque de Caroline Hillairet : prendre un quantile d'un objet incertain est mauvais. Comment y répondre sans abandonner la VaR, qui est imposée ?

L'idée. Deux réponses différentes, à ne pas confondre. **La VaR prédictive** intègre l'incertitude de paramètre dans la loi elle-même : on mélange les lois sur la loi a posteriori des paramètres, puis on prend le quantile du mélange. **La VaR robuste** prend le pire cas sur un ensemble d'ambiguïté : on ne mélange pas, on borne.

La formule.

$$\mathrm{VaR}_\alpha^{\text{préd}} = \mathrm{VaR}_\alpha\Big(\int f(\cdot \mid \theta)\,\pi(\theta)\,d\theta\Big), \qquad \mathrm{VaR}_\alpha^{\text{rob}} = \sup_{\theta\in\Theta}\ \mathrm{VaR}_\alpha(f(\cdot \mid \theta)).$$

Chez nous. Six postures, en M€ : point 657 ; prédictive 645 ± 7 (le 648 d'un autre calcul est le même nombre à la précision du bruit) ; robuste à $\beta = 90\,\%$ 939 ± 13, à 95 % $1\,037 \pm 9$, à 99 % $1\,247 \pm 24$; pire cas de modèle, ξ poussé à 0,90 : 1 331. **La prédictive coïncide presque avec le point** à 99,5 %, à deux fois le bruit ; elle ne s'en écarte qu'en profondeur, +4 % à 99,9 %. Et la robuste à 95 % est exactement la borne haute de l'intervalle déjà publié, 1 037 : la même quantité sous deux noms. Le mémoire reporte donc le point avec sa bande.

> **À dire à voix haute.** *Caroline a raison, et c'est mesurable. Ma réponse n'est pas d'abandonner la VaR, qui est imposée, mais de rendre l'incertitude visible sur trois étages. Et j'ai un résultat un peu contre-intuitif : la VaR prédictive coïncide presque avec la VaR ponctuelle. Ce n'est pas l'intégration qui manquait, c'est la largeur de bande qui est le vrai sujet.*

Le piège. Ne pas présenter la prédictive comme « la bonne réponse » qui remplacerait le point. Elle règle un problème (l'incertitude de paramètre) et pas l'autre (l'ambiguïté de modèle). C'est la robuste qui règle le second, et les deux ne se substituent pas. Et la posture la plus prudente est la moins précise : ± 24 à $\beta = 99\,\%$, quand les deux extrémités de l'échelle n'ont aucun bruit.

VIII. Les outils annexes

33 Le kappa de Cohen

Le problème. Deux codeurs lisent les mêmes récits. Comment mesurer leur accord, sachant que même deux personnes répondant au hasard seraient parfois d'accord par chance ?

La formule.

$$\kappa = \frac{p_o - p_e}{1 - p_e},$$

où p_o est l'accord observé et p_e l'accord attendu par pur hasard. $\kappa = 1$ est un accord parfait, $\kappa = 0$ un accord au niveau du hasard.

Chez nous. Le dispositif de second codage en aveugle est prêt : dix récits réduits aux faits, anonymisés, et une grille de 100 cellules dont 22 sont directionnelles dans le codage de référence, ce qui fixe la base d'accord (matériel complémentaire). Sans second jeu, le script ne fabrique aucun coefficient. Par convention, un κ au-delà de 0,6 se lit comme un accord substantiel ; en dessous, cela voudrait dire que la séquence des défaillances ne se lit pas de façon reproductible dans les rapports d'enquête, ce qui serait un résultat en soi.

> **À dire à voix haute.** *Le kappa corrige l'accord du hasard : deux personnes qui répondraient au hasard seraient parfois d'accord, et le kappa retranche cette part. Le second codage n'est pas encore reçu ; le dispositif est prêt, et il ne produit rien sans lui.*

34 La valeur d'information

L'idée. Une recommandation de reporting ne vaut rien tant qu'elle n'est pas chiffrée. On la chiffre en mesurant de combien la bande de capital rétrécit quand on acquiert l'information.

La formule. Avec $L(\mathcal{V}) = \sup_{\mathcal{V}} \mathrm{SCR} - \inf_{\mathcal{V}} \mathrm{SCR}$,

$$V(\mathcal{I}) = 1 - \frac{L(\mathcal{W}_{\mathcal{I}})}{L(\mathcal{W})} \in [0, 1].$$

Cette quantité est *monotone* (une information plus riche ne vaut pas moins) et *sans dimension* (donc comparable d'une source de sévérité à l'autre).

Chez nous. Si l'on retenait le sens que les sept premiers rapports documentent sur six dépendances, la largeur de la plage tomberait de 32,7 % en moyenne sur quatre graines, de 22 à 44 % selon la graine, sur une grille commune où chaque coefficient vaut $-S$, 0 ou S. Ce n'est pas un acquis : le mémoire n'en revendique que deux paires, et ce chiffre est un indicateur de ce qu'apporterait une information de cette étendue. Le premier calcul annonçait 66 % : il fixait les amplitudes à leur maximum, alors qu'un sens connu les laisse libres entre zéro et ce maximum. La valeur se **hiérarchise** sans se départager : quatre dépendances, dont gouvernance-incidents (13,3 %), lèvent chacune de 11,2 à 13,3 % en moyenne, leur ordre variant entre graines ; les cinq dernières n'en lèvent que de 0,7 à 2,3 %.

> **À dire à voix haute.** *J'ai chiffré ce que vaut, en capital, une donnée qu'on n'a pas. Une information de sens sur six dépendances resserrerait la plage d'un tiers en moyenne. Et surtout, quatre dépendances valent chacune beaucoup plus que les cinq autres : on sait où la donnée manque, sans pouvoir dire laquelle d'entre elles vaut le plus.*

Le piège. Même les dix sens connus (57,9 % de la plage levée), l'amplitude resterait inconnue. L'identification partielle n'est pas un état provisoire que la donnée finirait par lever, elle est structurelle.

35 Le bayésien conjugué

L'idée. Plutôt que d'estimer un signe de direction par oui ou non, on lui attribue une probabilité, qu'on met à jour avec les observations documentaires.

La formule. Modèle Beta-binomial : si $\theta \sim \mathrm{Beta}(\alpha_0, \beta_0)$ est la probabilité que la direction aille dans un sens, et qu'on observe n_{lo} transitions dans ce sens et n_{hi} dans l'autre, alors

$$\theta \mid \text{données} \;\sim\; \mathrm{Beta}(\alpha_0 + n_{lo},\ \beta_0 + n_{hi}),$$

et l'on pose $A = S\,(2\theta - 1)$, de sorte que $\theta = 1/2$ donne $A = 0$.

Chez nous. Le crédible à 90 % du capital est 81 % plus resserré que les bornes de pire cas. Sous un prior sceptique, la médiane ne bouge presque pas : la conclusion vient des comptes documentés. Mais seulement 2 paires documentées sur 6 ont un intervalle qui exclut 0,50, et les quatre paires que le corpus ne documente pas gardent un θ uniforme : le posterieur reproduit de lui-même l'identification partielle.

> **À dire à voix haute.** *Le bayésien me permet de dire « ce lien va probablement dans ce sens » au lieu de trancher par oui ou non. Deux résultats : le prior n'a presque aucune influence, ce qui est rassurant, et seulement deux paires sur six sont réellement tranchées, ce qui est honnête. Je publie les deux objets : la plage aux sommets, conditionnelle à S posée, et le crédible, qui ajoute un prior sur la direction.*

Le piège. Le bayésien ne crée pas d'information. Il exprime autrement la même incertitude, de façon plus lisible et plus fine, mais il ne remplace pas la donnée manquante.

IX. Du capital à la décision

36 À quelle échelle se lit un SCR

Le problème. Un capital de plusieurs milliards paraît absurde pour une compagnie d'assurance. C'est la première objection qu'on vous fera, et une clause de style n'y répond pas.

L'idée. La fréquence d'amorce et l'échelle des pertes changent avec la taille, puis le quantile annuel est recalculé. Le calcul d'entité utilise la cascade indépendante, sans choc commun P4 ; le chiffre de tête à quatre canaux utilise la marche auto-évitante avec ce choc. Les montants issus de ces deux protocoles ne se déduisent pas directement les uns des autres.

Chez nous.

Lecture	λ/an	**Sévérité**	**SCR**	**Moyenne**
Secteur financier mondial	21,56	×1	8 123 M€	983 M€
Seau « au moins dix événements »	0,210	×1	488 M€	9,7 M€
Seau « toutes firmes »	0,100	×1	229 M€	4,6 M€
λ lu à la taille de l'entité	0,092	×1	198 M€	4,3 M€
Les deux canaux composés	0,092	×0,854	**169** M€	3,6 M€

La dernière ligne est la lecture cohérente : fréquence *et* sévérité prises à la taille de l'entité. Sa bande sur les 1 024 sommets va de 131,5 à 183,3 M€.

> **À dire à voix haute.** *Les montants sectoriels concernent le périmètre financier étudié. Le calcul d'entité donne* 169 *M€ dans la lecture du registre, sous un état supposé. C'est une extrapolation d'ordre de grandeur : la forme de la sévérité reste celle de grandes institutions. Rien ne garantit que ce montant majore le besoin réel. Le critère conventionnel de poids dans le SCR ne définit pas un domaine de validité statistique.*

Le piège. La non-linéarité est le vrai résultat. Diviser λ par 235 divise la moyenne par 270, donc à proportion, mais ne divise le capital que par 48 : c'est le **principe du grand saut unique**, le quantile d'une entité décrivant un sinistre isolé et non une accumulation. Diviser le capital du secteur par le nombre d'entités le sous-estimerait d'un facteur de l'ordre de cinq. Et le repère de 3 % des provisions n'est qu'un ordre de grandeur : il s'écarte de −8 % et +56 % des modules publiés dans les SFCR.

Le piège. La descente d'échelle ne distingue ni la taille fine ni le métier. Les élasticités à la taille valent 0,074 pour la fréquence et 0,087 pour la sévérité : une petite entité subit presque la sévérité d'un grand groupe, donc sa charge rapportée au SCR est plus forte. Un essai exploratoire, hors rapport, l'illustre. À taille égale, l'assurance a environ 0,5 fois la fréquence de la banque et environ 2,4 fois sa sévérité ; un plafond par sinistre proportionnel à l'exposition ($\kappa\times$ actifs) ferait suivre la charge à la taille. Mais le plafond κ serait posé, la base ne couvre pas les petites entités, et le quantile à 99,5 % d'un petit assureur tombe à zéro. Piste d'amélioration, pas résultat.

37 Détenir ou transférer

Le problème. Le mémoire compare son SCR à la Formule Standard, aux pertes réelles et au marché cyber. Trois comparaisons de *niveau*. Il en manque une de *prix*.

L'idée. Un SCR n'est pas une perte, c'est du capital **immobilisé**, et le capital coûte. Solvabilité II chiffre ce coût explicitement. En face, transférer coûte une prime. Les deux grandeurs sont homogènes, donc comparables, et c'est l'arbitrage que fait un directeur des risques.

La formule. Le coût annuel de détention vaut CoC × SCR, où CoC est le taux de coût du capital de la marge de risque : 6 % historiquement, ramené à **4,75** % par la directive (UE) 2025/2. Pour un traité en excès de perte annuel de portée L, on minimise

$$\text{coût}(L) = \underbrace{\mathbb{E}[\min(X, L)]/0{,}485}_{\text{prime}} + \text{CoC} \times \underbrace{\text{VaR}_{99{,}5\%}(X - \min(X, L))}_{\text{capital résiduel}}.$$

Chez nous. Multiple de capital $\text{SCR}/\mathbb{E}[X] = \mathbf{47}$ à l'échelle entité contre 8,3 au secteur. Coût de détention 8,0 M€/an au taux révisé (10,1 à 6 %) contre 3,6 M€ de sinistralité attendue, soit

2,2 à 2,8 fois. Le capital résiduel vaut $\max(\text{SCR} - L, 0)$, donc l'optimum tombe exactement en $L^\star = \text{SCR} = 169$ M€, et le coût de financement passe à **2,9** M€, soit $-$**64** %; pertes conservées comprises, de 11,67 à 5,12 M€, soit -56 %. Une entité devenue conforme (fréquence de 0,092 à 0,046) voit en outre ce coût optimal baisser de 60 % : la conformité déplace le point d'équilibre entre rétention et transfert.

À dire à voix haute. *Immobiliser le capital coûte deux fois et demie ce que le risque coûte en moyenne. Près de l'optimum, un euro de portée coûte un peu plus d'un pour cent de prime et libère quatre virgule sept cinq pour cent de coût du capital. C'est pour ça que le transfert domine, et c'est un calcul, pas une opinion.*

Le piège. Le « coût total » s'appelle désormais coût de *financement* (prime et coût du capital), et ne comprend pas les pertes conservées. Ce gain est une **borne supérieure**, pour trois raisons : la capacité du marché plafonne près de 500 M€ sur un seul risque ; les polices excluent la guerre et les infrastructures essentielles ; et sous Solvabilité II céder ne supprime pas l'exigence, cela *substitue* au risque cyber un risque de **défaut de contrepartie**. En résumant les trois par la part de la portée achetée qui reste sans allègement de capital, le transfert reste préférable, face au meilleur traité, tant que cette part est inférieure à **64** % (81,5 % pertes conservées comprises) : il faudrait que près des deux tiers de la couverture soient inefficaces pour renverser la conclusion. La conclusion est robuste, le chiffre ne l'est pas.

Compléments Institut après dépôt

Cette partie porte sur la version Institut et les analyses des 27 et 28 octobre. Elle ne change pas les folios du rapport ENSAE cités dans le cours. Le rapport déposé décrit 582 pertes et 91 excès ; les analyses Institut sur 2000–2026 retiennent 570 pertes et 86 excès. Toujours annoncer le périmètre et dire si le résultat est dans le rapport ou constitue un complément. Le protocole de capital publié ne devient pas validé par l'ajout de ces diagnostics.

38 Trois lectures de la taille

Le problème. Le registre observe les pertes déclarées, sans donner une exposition exhaustive. Une faible relation entre actifs et incidents enregistrés ne prouve pas une faible relation entre actifs et risque réel.

La formule. Pour une entité d'actifs A,

$$\lambda(A) = \Lambda \frac{A^{b_\lambda}}{\overline{\sum_j A_j^{b_\lambda}}}, \qquad m(A) = \left(\frac{A}{A_m}\right)^b, \qquad B(A) = \mathrm{VaR}_{99,5\%}\left(\sum_{n=1}^{N} m(A) \sum_{k \in S_n} Y_{n,k}\right).$$

Λ est le nombre moyen d'incidents du panel ; j parcourt ses firmes actives et la barre est une moyenne annuelle. A_m est la taille médiane des pertes retenues ; b règle l'échelle des pertes. N est le nombre annuel d'incidents, S_n les piliers atteints et $Y_{n,k}$ leurs pertes élémentaires. Le capital est recalculé après les deux changements d'échelle.

Chez nous. Le panel financier avec actifs connus porte sur 2005–2022, avec $\Lambda = 79{,}0$ et 808 firmes actives en moyenne. Trois valeurs de b_λ sont examinées : 0,074 (registre), 0,27 (centrale posée), 1 (proportionnelle à l'exposition). L'élasticité $b = 0{,}087$ est estimée sur les pertes TIC du panel ; son application à la sévérité cyber-finance est une hypothèse de transfert. Aucun coefficient métier n'est estimé dans ce moteur.

Le piège. Le calcul d'entité utilise la cascade indépendante sans choc commun P4. Le chiffre de tête à quatre canaux utilise la marche avec ce choc ; les 32 configurations par pilier utilisent la marche sans ce choc. Une validation obtenue sur l'un de ces protocoles ne se transfère pas automatiquement aux autres.

À dire à voix haute. *La descente d'échelle adapte fréquence et montants, puis recalcule le quantile. Les trois lectures exposent l'incertitude sur l'exposition. Le* 169 *M€ est la lecture du registre pour l'entité notionnelle ; il ne garantit pas une couverture prudente de son besoin réel.*

Appui : Mémoire Institut, § 9.8–9.9 ; sortie du script 130. Les unités monétaires d'actifs sont converties avant application des élasticités ; ne pas mélanger M$ et M€.

39 Un quantile nul n'est pas une absence d'incident

La formule. Pour une perte annuelle non négative L,

$$\mathbb{P}(L = 0) \geq 0{,}995 \quad \Longrightarrow \quad \mathrm{VaR}_{99,5\%}(L) = 0.$$

La condition porte sur la *perte*, pas sur le seul nombre N d'incidents. Dans le moteur, une perte élémentaire est nulle si elle ne dépasse pas le seuil monétaire. Un incident compté peut donc ne produire aucune charge positive.

Chez nous. Pour l'assureur A en lecture centrale, le script 130 donne environ 0,99 % de probabilité d'au moins un incident, mais 0,49 % de charge de queue positive. Le quantile est nul malgré des

incidents possibles. Les tailles de bascule de 2 517 et 141 079 M€ sont obtenues sur une seule graine et restent des ordres de grandeur.

À dire à voix haute. *La VaR nulle reflète la masse en zéro de la charge simulée à ce niveau de probabilité. Un quantile plus élevé, ou une autre mesure de perte, peut informer autrement le risque. Cette bascule ne définit pas la validité statistique du modèle.*

40 Apprentissage statistique : un gain à vérifier hors période d'ajustement

L'idée. Le script 131 demande si les caractéristiques observées améliorent une simple tendance temporelle. Il prédit le dépassement de $u = 20{,}03$ M€ parmi les pertes enregistrées. Ce n'est ni une fréquence annuelle d'incidents ni une mesure de conformité.

Chez nous. Évaluation en origine glissante de 2014 à 2025 : 280 pertes, 60 dépassements. M0 est un taux constant ; M1 une tendance logistique ; M2 une logistique pénalisée enrichie ; M3 un boosting sur l'année, le métier, la région, la catégorie et les actifs. Les hyperparamètres sont fixés avant l'évaluation ; l'incertitude est calculée par bootstrap des douze années évaluées. Le gain de log-score de M3 contre M1 vaut +0,0193, intervalle à 90 % [−0,0371 ; +0,0571]. Aucun gain positif résolu n'est établi dans les variantes testées.

Le piège. Pour 37 % des pertes, les actifs décrivent une information financière postérieure à l'incident. Les masquer ne fait pas apparaître de gain résolu. La variante GPD à covariables attribue une densité nulle à un excès observé : sa moyenne sur les 59 autres excès omet cet échec de support et ne peut pas être présentée comme son score complet.

À dire à voix haute. *Le boosting a le meilleur score moyen, mais le gain n'est pas distingué de zéro avec la précision disponible. Ce diagnostic ne prouve pas que les caractéristiques sont inutiles ; il ne justifie pas de remplacer ici le modèle de référence.*

Appui : Mémoire Institut, § 4.7.1 ; script 131 et sortie 131, après dépôt ENSAE.

41 Descriptions SAS : observer un récit et identifier un mécanisme

L'idée. Le script 132 est un pilote de 50 descriptions ; le script 133 agrège le codage de 570 descriptions, pilote inclus. Au niveau strict, le texte établit une défaillance ; au niveau large, le codeur ajoute une défaillance impliquée. Un seul assistant IA a codé ces textes.

Chez nous. Le corpus complet contient 65 incidents multi-piliers au sens strict et 203 au sens large. La corrélation de rang avec la matrice d'expert est de 0,67 et 0,75 pour les co-occurrences brutes, mais de 0,33 et 0,12 pour les coefficients ϕ, qui tiennent compte des marges. Une forte fréquence de P1 contribue donc à l'accord brut apparent.

Le piège. Ces codes ne sont pas des défaillances mesurées et n'estiment ni S ni A. Aucune direction n'est codée. Un second codage est préparé sur 100 descriptions, 50 par strate, avec questionnaire en aveugle et clé séparée. Les réponses ne sont pas encore reçues : aucun accord intercodeurs n'est annoncé. Le pilote et le corpus complet ne sont pas deux validations indépendantes.

À dire à voix haute. *Les textes peuvent aider à préciser ce qu'il faudrait observer. Avant de s'en servir pour estimer un lien, il faut vérifier que deux lecteurs indépendants y repèrent les mêmes faits, puis relier ces faits aux variables du modèle.*

Appui : Scripts 132–133 ; protocole `docs/protocoles/validation_codage_sas.md`. Les textes sous licence et la clé ne font pas partie des fichiers à publier.